문서 분류 시스템 구현 보고서

작성일: 2026-02-10 | 버전: 1.1.0

1. 프로젝트 개요

1.1 목적

의료/보험 문서를 자동으로 분류하는 3단계 파이프라인 시스템 구축

1.2 분류 대상 문서 (6종)

번호	문서 유형	영문명	번호	문서 유형	영문명
1	진단서	Diagnosis	4	입퇴원확인서	Admission/Discharge
2	소견서	Medical Opinion	5	의료비영수증	Medical Receipt
3	보험금청구서	Insurance Claim	6	처방전	Prescription

2. 시스템 아키텍처

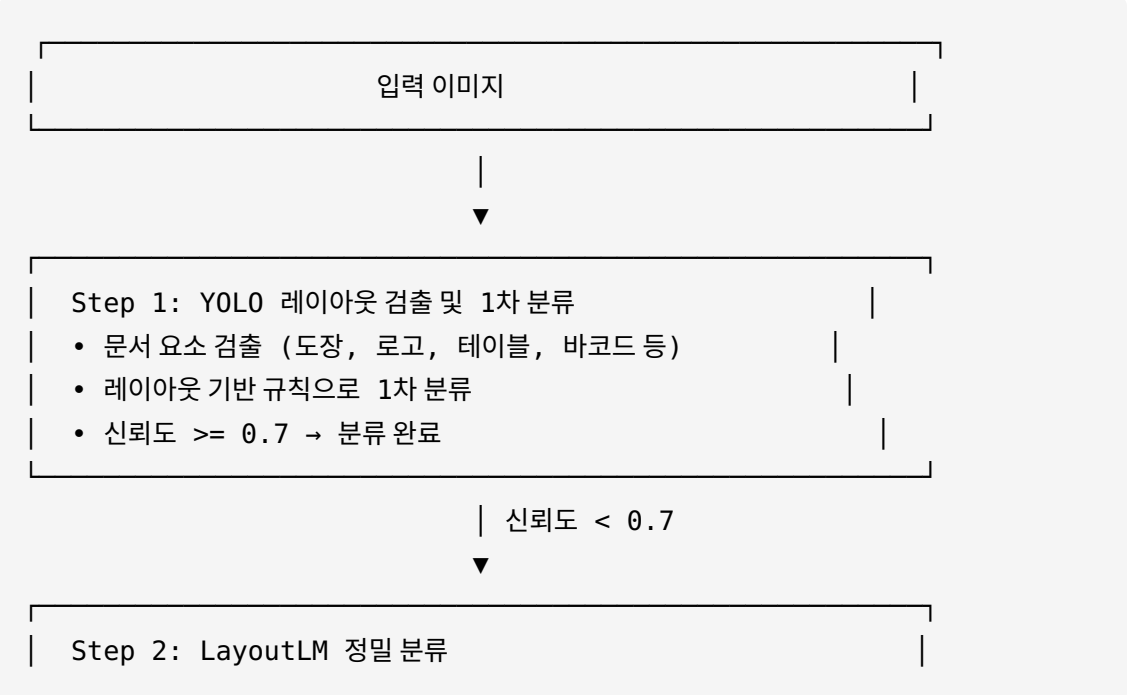

```
│   • EasyOCR 실제 텍스트 추출                                    │
│   • 텍스트 + 레이아웃 기반 정밀 분류                            │
│   • 신뢰도 >= 0.7 → 분류 완료                                   │
└─────────────────────────────────────────────────────────────────┘
                                  │ 신뢰도 < 0.7
                                  ▼
┌─────────────────────────────────────────────────────────────────┐
│  Step 3: VLM 예외 처리 (미구현)                                 │
│   • GPT-4V 또는 Claude Vision 활용                              │
│   • 복잡한 문서에 대한 최종 판단                                │
└─────────────────────────────────────────────────────────────────┘
```

---

3. 데이터셋 구성

2.1 샘플 데이터 생성

실제 의료 문서 데이터가 없어 합성 데이터를 생성하여 사용

생성 방식

- Python PIL 라이브러리를 사용하여 각 문서 유형별 템플릿 이미지 생성
- 문서 유형별 특징적인 레이아웃 요소 배치:
- 병원 로고, 도장, 서명, 테이블, 바코드, QR코드 등

데이터 규모

구분	문서 수	이미지 수
학습 (train)	6종 × 50개	300개
검증 (val)	6종 × 10개	60개
합계	-	360개

2.2 문서 유형별 레이아웃 특성

문서 유형	필수 요소	선택 요소	금지 요소
진단서	도장, 병원로고	서명	테이블, 바코드, QR코드
소견서	도장, 병원로고	서명	테이블, 바코드, QR코드
보험금청구서	테이블, 바코드	도장, 서명, 병원로고	QR코드

문서 유형	필수 요소	선택 요소	금지 요소
입퇴원확인서	도장, 병원로고, 테이블	-	바코드, QR코드
의료비영수증	테이블, 바코드	도장, 병원로고	QR코드
처방전	테이블, QR코드	도장, 병원로고, 서명	바코드

2.3 YOLO 학습 데이터

- 형식: YOLO 형식 (이미지 + 라벨 텍스트 파일)
- 클래스 수: 6개 `0: stamp (도장) 1: signature (서명) 2: table (테이블) 3: barcode (바코드) 4: qrcode (QR코드) 5: hospital_logo (병원 로고)`

2.4 LayoutLM 학습 데이터

- 형식: 이미지 + OCR 텍스트 + 바운딩 박스
- OCR 데이터: 문서 유형별 키워드 기반 Mock OCR 생성
- 진단서: "진단서", "진단명", "상병명", "질병분류", "진단코드" 등
- 소견서: "소견서", "의료소견", "치료소견", "치료경과" 등
- 보험금청구서: "보험금청구서", "청구금액", "계좌번호", "피보험자" 등
- 입퇴원확인서: "입퇴원확인서", "입원일", "퇴원일", "입원기간" 등
- 의료비영수증: "진료비영수증", "본인부담금", "급여", "비급여" 등
- 처방전: "처방전", "처방의약품", "약품명", "투약일수" 등

---

4. Step 1: YOLO 모델

3.1 모델 구성

- 베이스 모델: YOLOv8n (ultralytics)
- 학습 에포크: 50
- 이미지 크기: 640×640
- 배치 크기: 16

3.2 학습 결과

```
Epoch 50/50 완료
- Box Loss: 0.5765
- Class Loss: 0.3342
- DFL Loss: 0.8823
```

3.3 검증 성능 (Validation)

전체 성능

메트릭	값
mAP50	99.5%
mAP50-95	96.0%
Precision	98.7%
Recall	98.8%

클래스별 AP50

클래스	AP50
stamp	99.5%
signature	99.5%
table	99.5%
barcode	99.5%
qrcode	99.5%
hospital_logo	99.5%

3.4 1차 분류 성능

문서 유형별 정확도

문서 유형	정확도	비고
진단서	10/10 (100%)	-
소견서	0/10 (0%)	진단서로 오분류
보험금청구서	10/10 (100%)	-
입퇴원확인서	10/10 (100%)	-
의료비영수증	10/10 (100%)	-
처방전	10/10 (100%)	-
전체	50/60 (83.3%)	-

분석

- 진단서/소견서 혼동: 두 문서 유형이 동일한 레이아웃 특성(도장+병원로고, 테이블 없음)을 가져 YOLO 기반 분류로는 구분 불가
- 해결 방안: Step 2 (LayoutLM)에서 텍스트 기반 분류로 해결

---

5. Step 2: LayoutLM 모델

4.1 모델 구성

- 베이스 모델: microsoft/layoutlmv3-base
- 학습 에포크: 5
- 배치 크기: 2
- 최대 시퀀스 길이: 512
- 학습률: 5e-5 (warmup steps: 30)

4.2 학습 결과

에포크별 성능

Epoch	Train Loss	Eval Loss	Eval Accuracy
1	0.0030	0.0011	100%
2	0.0020	0.0011	100%
3	0.0014	0.0007	100%
4	0.0012	0.0006	100%
5	0.0010	0.0006	100%

4.3 검증 성능

문서 유형별 정확도

문서 유형	정확도
진단서	10/10 (100%)
소견서	10/10 (100%)
보험금청구서	10/10 (100%)

문서 유형	정확도
입퇴원확인서	10/10 (100%)
의료비영수증	10/10 (100%)
처방전	10/10 (100%)
전체	60/60 (100%)

4.4 실제 OCR 적용 결과

v1.1에서 Mock OCR 대신 EasyOCR을 적용하여 검증한 결과:

문서 유형	Mock OCR	Real OCR (EasyOCR)
진단서	10/10 (100%)	10/10 (100%)
소견서	10/10 (100%)	10/10 (100%)
보험금청구서	10/10 (100%)	10/10 (100%)
입퇴원확인서	10/10 (100%)	10/10 (100%)
의료비영수증	10/10 (100%)	10/10 (100%)
처방전	10/10 (100%)	10/10 (100%)
전체	60/60 (100%)	60/60 (100%)

- Mock OCR로 학습된 모델이 실제 EasyOCR 결과에서도 동일한 100% 정확도 달성
- EasyOCR이 합성 이미지의 한글 텍스트를 안정적으로 인식

4.5 핵심 성과

- 진단서/소견서 완벽 구분: Step 1에서 구분 불가했던 두 문서 유형을 텍스트 기반으로 100% 정확하게 분류
- 높은 신뢰도: 대부분의 분류에서 신뢰도 0.99 이상 달성
- 실제 OCR 호환: Mock OCR 학습 모델이 실제 OCR 환경에서도 성능 유지

---

6. Step 1 vs Step 2 비교

항목	Step 1 (YOLO)	Step 2 (LayoutLM)
분류 방식	레이아웃 요소 기반	EasyOCR 텍스트 + 레이아웃 기반

항목	Step 1 (YOLO)	Step 2 (LayoutLM)
전체 정확도	83.3%	100%
진단서/소견서 구분	불가능	가능
처리 속도 (이미지당)	~0.1초	~2초
적합한 상황	레이아웃이 뚜렷한 문서	텍스트 구분이 필요한 문서

---

7. API 서버

6.1 기술 스택

- 프레임워크: FastAPI
- 서버: Uvicorn
- 문서: Swagger UI (자동 생성)

6.2 엔드포인트

엔드포인트	메서드	설명
`/`	GET	API 정보
`/health`	GET	헬스 체크 및 모델 로드 상태
`/classes`	GET	지원 문서 클래스 목록
`/classify`	POST	단일 문서 분류
`/classify/batch`	POST	배치 문서 분류
`/docs`	GET	Swagger UI

6.3 주요 변경사항 (v1.1)

- 실제 OCR 기본 적용: `use_mock_ocr` 기본값이 `False` 로 변경되어 EasyOCR이 기본 동작
- 모델 프리로드: 서버 시작 시 YOLO, LayoutLM, EasyOCR 3개 모델을 모두 로드하여 첫 요청 지연 제거
- OCR 프로세서 캐싱: EasyOCR을 전역 캐싱하여 매 요청마다 재초기화 방지
- 빈 OCR 결과 처리: OCR에서 텍스트를 검출하지 못한 경우 422 에러 반환

6.4 분류 API 응답 예시


```
{
  "predicted_class": "진단서",
  "confidence": 0.9972,
  "final_step": 2,
  "processing_time": 4.11,
  "step1_result": {
    "predicted_class": "진단서",
    "confidence": 1.0,
    "requires_step2": false
  },
  "step2_result": {
    "predicted_class": "진단서",
    "confidence": 0.9972,
    "all_probabilities": {
      "진단서": 0.9972,
      "소견서": 0.0008,
      "보험금청구서": 0.0005,
      "입퇴원확인서": 0.0006,
      "의료비영수증": 0.0005,
      "처방전": 0.0004
    },
    "ocr_words_count": 21,
    "mock_ocr_used": false
  }
}
```


---

8. 프로젝트 구조

```
문서분류기/
├── api/
│   ├── __init__.py
│   └── app.py                  # FastAPI 앱
├── config/
│   └── config.yaml             # 전체 설정
├── src/
│   ├── pipeline.py             # 메인 파이프라인
│   ├── preprocessor/           # 전처리 (기울기 보정 등)
│   ├── step1_yolo/             # YOLO 검출 및 분류
│   ├── step2_layoutlm/         # LayoutLM 분류 및 OCR
```

```
│   ├── step3_vlm/              # VLM 예외 처리 (placeholder)
│   └── utils/                  # 유틸리티
├── scripts/
│   ├── train_yolo.py           # YOLO 학습
│   ├── train_layoutlm_simple.py # LayoutLM 학습
│   ├── test_step1_classifier.py # Step 1 테스트
│   ├── test_step2_layoutlm.py   # Step 2 테스트
│   ├── test_real_ocr.py        # 실제 OCR vs Mock OCR 비교 테스트
│   └── test_api.py             # API 테스트
├── data/
│   ├── models/                 # 학습된 모델
│   ├── yolo_dataset/           # YOLO 학습 데이터
│   └── sample/                 # 샘플 데이터
├── run_api.py                  # API 서버 실행
└── requirements.txt            # 의존성
```

---

9. 실행 방법

8.1 환경 설정

```
pip install -r requirements.txt
```

8.2 API 서버 실행

```
python run_api.py
```

8.3 테스트

```
 # Step 1 테스트
python scripts/test_step1_classifier.py

# Step 2 테스트
python scripts/test_step2_layoutlm.py

# 실제 OCR vs Mock OCR 비교 테스트
python scripts/test_real_ocr.py
```

```
# API 테스트
python scripts/test_api.py
```

---

10. 향후 개선 사항

9.1 단기

- [ ] Step 3 (VLM) 구현: GPT-4V 또는 Claude Vision 연동
- [x] ~~실제 OCR 적용~~: EasyOCR 통합 완료 (v1.1), 검증셋 100% 정확도 확인
- [ ] 전처리 파이프라인 활성화: 기울기 보정, 문서 영역 검출

9.2 중기

- [ ] 실제 의료 문서 데이터 수집 및 학습
- [ ] 모델 경량화 및 추론 속도 최적화
- [ ] Docker 컨테이너화

9.3 장기

- [ ] 추가 문서 유형 지원
- [ ] 다국어 지원
- [ ] 클라우드 배포 (AWS/GCP)

---

11. 결론

3단계 파이프라인 기반 문서 분류 시스템을 성공적으로 구현했습니다.

주요 성과: 1. YOLO 기반 레이아웃 검출: mAP50 99.5% 달성 2. LayoutLM 기반 정밀 분류: 100% 정확도 달성 3. 진단서/소견서 구분 문제 해결: Step 2에서 텍스트 기반 분류로 완벽 구분 4. 실제 OCR 통합: EasyOCR 적용 후에도 6종 문서 전체 100% 정확도 유지 5. REST API 제공: FastAPI 기반 서비스 API 구현 (실제 OCR 기본 동작)

성능 지표: | 항목 | 수치 | |---|---| | Step 1 처리 시간 | ~0.1초/이미지 | | Step 2 처리 시간 | ~2초/이미지 | | Step 1 정확도 | 83.3% (진단서/소견서 혼동) | | Step 2 정확도 (Mock OCR) | 100% | | Step 2 정확도 (Real OCR) | 100% |

합성 데이터 기반으로 개발되었으므로, 실제 의료 문서 데이터로 추가 학습 시 성능 검증이 필요합니다.

작성자: Claude Opus 4.6 (Co-authored with BongwooChoi)