

# 문서 분류기

이 레포지토리는 문서 분류기를 위한 코드와 데이터를 제공합니다.

## 설치

1. [Python 3.7 이상](#) (Python 3.7 이상)
2. [Git](#) 설치
3. [PyTorch](#) 설치
4. [Transformers](#) 설치
5. [Ultralytics](#) 설치
6. [NLTK](#) 설치
7. [API](#) 설치

## 1. 데이터셋 (Dataset)

### 1.1 데이터셋 다운로드

```
# GitHub에서 데이터셋을 다운로드 받기
git clone https://github.com/BongwooChoi/doc-classifier.git
cd doc-classifier
```

### 1.2 Python 패키지 설치

```
# 패키지 설치 디렉토리 생성
mkdir -p offline_packages

# wheel을 사용하여 패키지 다운로드
pip download -r requirements.txt -d offline_packages

# PyTorch를 사용하여 패키지 다운로드 (requirements.txt에 정의된 패키지)
pip download torch torchvision --index-url https://download.pytorch.org/whl/cpu -d offline_packages
pip download ultralytics -d offline_packages
pip download transformers -d offline_packages
```

```

pip download easyocr -d offline_packages
pip download fastapi uvicorn python-multipart -d offline_packages
pip download pillow numpy opencv-python -d offline_packages
pip download pyyaml tqdm -d offline_packages
pip download accelerate datasets -d offline_packages

```

### 1.3 Hugging Face YOLOv8 YOLOv8

```

# YOLOv8 YOLOv8 YOLOv8
mkdir -p offline_models/layoutlmv3-base

# PythonYOLOv8 YOLOv8 YOLOv8
python3 << 'EOF'
from transformers import LayoutLMv3Processor, LayoutLMv3ForSequenceClassification

model_name = "microsoft/layoutlmv3-base"
save_path = "offline_models/layoutlmv3-base"

# YOLOv8 YOLOv8
processor = LayoutLMv3Processor.from_pretrained(model_name, apply_ocr=False)
processor.save_pretrained(save_path)

# YOLOv8 YOLOv8 (YOLOv8 YOLOv8)
model = LayoutLMv3ForSequenceClassification.from_pretrained(
    model_name,
    num_labels=6
)
model.save_pretrained(save_path)

print(f"YOLOv8 YOLOv8 YOLOv8: {save_path}")
EOF

```

### 1.4 YOLO YOLOv8 YOLOv8 YOLOv8

```

# YOLO YOLOv8 YOLOv8
python3 << 'EOF'
from ultralytics import YOLO

# YOLOv8n YOLOv8 (YOLOv8 yolov8n.pt YOLOv8)
model = YOLO("yolov8n.pt")
print("YOLO YOLOv8 YOLOv8 YOLOv8: yolov8n.pt")
EOF

# YOLOv8 YOLOv8 offline_models YOLOv8
cp yolov8n.pt offline_models/

```

## 1.5 EasyOCR 실행 준비

```
# EasyOCR 실행 준비 (터미널 + CMD)
python3 << 'EOF'
import easyocr

# 한글+영어 실행 준비 (이 실행 후 실행 가능)
reader = easyocr.Reader(['ko', 'en'], gpu=False)
print("EasyOCR 실행 준비 완료")

# 실행 디렉토리
import os
easyocr_model_path = os.path.expanduser("~/EasyOCR/model")
print(f"EasyOCR 실행 디렉토리: {easyocr_model_path}")
EOF

# EasyOCR 실행 디렉토리
mkdir -p offline_models/easyocr
cp -r ~/.EasyOCR/model/* offline_models/easyocr/
```

## 1.6 디렉토리 확인

```
# 디렉토리 확인
find offline_packages -name "*.whl" | head -20
ls -la offline_models/
ls -la offline_models/layoutlmv3-base/
ls -la offline_models/easyocr/
```

## 1.7 패키지 다운로드

```
# 패키지 다운로드 (터미널 + CMD)
cd ..
tar -czvf doc-classifier-offline.tar.gz doc-classifier/
```

다운로드된 패키지 구조: - doc-classifier/ - 패키지 목록 - doc-classifier/offline\_packages/ - Python 패키지 (~2-3GB) - doc-classifier/offline\_models/ - 모델 파일 (~1-2GB)

---

## 2. 离线部署 模型 数据

### 2.1 模型 数据 下载

文件/目录	大小 (GB)	说明
doc-classifier-offline.tar.gz	3-5GB	模型 数据 包

### 2.2 部署 环境

- USB 存储设备
- 模型 数据 包
- 模型 数据 包 解压 目录

## 3. 模型 部署 步骤

### 3.1 模型 部署

```
# 模型 部署 目录
cd /path/to/workspace

# 模型 数据
tar -xzf doc-classifier-offline.tar.gz
cd doc-classifier
```

### 3.2 Python 环境 配置 (Linux)

```
# 创建 虚拟 环境
python3 -m venv venv

# 激活 虚拟 环境 (Linux/Mac)
source venv/bin/activate

# 激活 虚拟 环境 (Windows)
# venv\Scripts\activate
```

### 3.3 离线安装依赖包

```
# 离线安装依赖包 (离线包在 3.2 节中)
pip install --no-index --find-links=offline_packages torch torchvision
pip install --no-index --find-links=offline_packages ultralytics
pip install --no-index --find-links=offline_packages transformers
pip install --no-index --find-links=offline_packages easyocr
pip install --no-index --find-links=offline_packages fastapi uvicorn python-multipart
pip install --no-index --find-links=offline_packages pillow numpy opencv-python
pip install --no-index --find-links=offline_packages pyyaml tqdm
pip install --no-index --find-links=offline_packages accelerate datasets

# 安装 requirements.txt 中的依赖包
pip install --no-index --find-links=offline_packages -r requirements.txt
```

### 3.4 运行推理

```
# 运行推理
python3 << 'EOF'
import torch
print(f"PyTorch: {torch.__version__}")

import ultralytics
print(f"Ultralytics: {ultralytics.__version__}")

import transformers
print(f"Transformers: {transformers.__version__}")

import easyocr
print("EasyOCR: OK")

import fastapi
print(f"FastAPI: {fastapi.__version__}")

print("\n所有依赖包安装成功!")
EOF
```

### 3.5 部署推理服务

```
# YOLO 模型推理
cp offline_models/yolov8n.pt ./

# EasyOCR 推理 (在 3.2 节中)
```

```
mkdir -p ~/.EasyOCR/model
cp -r offline_models/easyocr/* ~/.EasyOCR/model/
```

## 4. 数据集准备

### 4.1 生成样本数据

```
# 生成样本数据
python3 scripts/generate_sample_data.py
```

生成数据:

```
data/sample/
├── train/
│   ├── images/      # 480 张图片 (60 × 80)
│   ├── annotations/ # 480 个 JSON
│   └── labels.tsv
└── test/
    ├── images/      # 120 张图片 (60 × 20)
    ├── annotations/ # 120 个 JSON
    └── labels.tsv
```

### 4.2 YOLO 数据集准备

```
# YOLO 数据集准备
python3 scripts/generate_yolo_dataset.py
```

生成数据:

```
data/yolo_dataset/
├── images/
│   ├── train/ # 3000 张图片
│   └── val/   # 600 张图片
├── labels/
│   ├── train/ # 3000 个标注
│   └── val/   # 600 个标注
└── data.yaml  # YOLO 数据集配置
```

## 4.3 環境 構築

```
# 環境 構築
echo "Train images: $(ls data/yolo_dataset/images/train/*.jpg 2>/dev/null | wc -l)"
echo "Val images: $(ls data/yolo_dataset/images/val/*.jpg 2>/dev/null | wc -l)"

# data.yaml 確認
cat data/yolo_dataset/data.yaml
```

## 5. 実行 開始

### 5.1 Step 1: YOLO 実行

```
# YOLO 実行
python3 scripts/train_yolo.py
```

実行 時間: 30分 ~ 1時間 (CPU 依存)

実行 結果:

```
Epoch 1/50 ...
Epoch 2/50 ...
...
Epoch 50/50 完了!
```

実行 結果 確認:

```
runs/detect/train/weights/best.pt
```

### 5.2 YOLO 結果 確認

```
# 結果 確認 用 環境 構築
mkdir -p data/models/yolo_document_layout/weights
cp runs/detect/train/weights/best.pt data/models/yolo_document_layout/weights/
```

## 5.3 Step 1 실행

```
# YOLO 실행 실행
python3 scripts/test_step1_classifier.py
```

실행 결과:

```
실행 결과 출력:
  클래스: 10/10 (100.0%)
  클래스: 0/10 (0.0%) ← 클래스 이름 (클래스)
  클래스명: 10/10 (100.0%)
  클래스명: 10/10 (100.0%)
  클래스명: 10/10 (100.0%)
  클래스: 10/10 (100.0%)

  실행 결과: 50/60 (83.3%)
```

## 5.4 Step 2: LayoutLM 실행

```
# LayoutLM 실행 실행 (오프라인 실행 실행)
python3 scripts/train_layoutlm_simple.py
```

실행: 오프라인 실행 실행 실행 실행 실행

실행 실행 실행 ( scripts/train\_layoutlm\_simple.py ):

```
# 실행 (오프라인)
# model_name = "microsoft/layoutlmv3-base"

# 실행 (오프라인)
model_name = "offline_models/layoutlmv3-base"
```

실행 실행 실행 실행 실행 실행:

```
export TRANSFORMERS_OFFLINE=1
export HF_DATASETS_OFFLINE=1
```

실행 실행 실행: 40 ~ 1 (CPU 실행)

실행 실행 실행:



```
Epoch 1/5: eval_accuracy=1.0
Epoch 2/5: eval_accuracy=1.0
...
Epoch 5/5: eval_accuracy=1.0
```

이제 이 파일을 실행합니다:

```
data/models/layoutlm_classifier/best/
```

## 5.5 Step 2 실행

```
# LayoutLM 실행
python3 scripts/test_step2_layoutlm.py
```

이제 실행:

```
이제 실행 결과:
  10/10 (100.0%)
  10/10 (100.0%) ← Step 1의 모든 데이터셋이 성공적으로 로드되었습니다.
  10/10 (100.0%)
  10/10 (100.0%)
  10/10 (100.0%)
  10/10 (100.0%)
  10/10 (100.0%)

총 실행 시간: 60/60 (100.0%)
```

---

## 6. 통합 테스트

### 6.1 통합 테스트 실행

```
# Step 1 + Step 2 통합 테스트
python3 scripts/test_pipeline_integration.py
```

### 6.2 통합 테스트 결과

```
python3 << 'EOF'
import sys
sys.path.insert(0, '.')

```

```

from src.step1_yolo.detector import YOLODetector
from src.step1_yolo.classifier import YOLOClassifier

# YOLO 실행 코드
detector = YOLODetector(
    model_path="data/models/yolo_document_layout/weights/best.pt"
)
classifier = YOLOClassifier(detector=detector)

# 실행 결과 출력
result = classifier.classify("data/yolo_dataset/images/val/diagnosis_0040.jpg")
print(f"결과: {result['predicted_class']}")
print(f"확률: {result['confidence']:.2f}")
EOF

```

## 7. API 실행 코드

### 7.1 실행 코드

```

# API 실행 코드
python3 run_api.py

```

결과:

```

=====
결과 결과 API 실행 결과
=====

결과 URL: http://localhost:8000
API 결과: http://localhost:8000/docs

```

### 7.2 API 테스트

테스트 1: 결과 결과 결과

테스트 2: 결과 결과

```

# API 테스트 코드
python3 scripts/test_api.py

```

## 7.3 curl 测试

```
# 测试 接口
curl http://localhost:8000/health

# 测试 接口 并 上传 文件
curl -X POST "http://localhost:8000/classify?use_mock_ocr=true" \
-F "file=@data/yolo_dataset/images/val/diagnosis_0040.jpg"
```

## 7.4 测试接口 步骤

1. 访问 `http://localhost:8000/docs` 页面
2. `/classify` 接口 测试
3. "Try it out" 按钮
4. 输入 文件 路径
5. "Execute" 按钮
6. 查看 结果

## 8. 部署

### 8.1 安装 依赖

错误: No matching distribution found

```
# 解决: 使用 离线 安装 方式
pip download [package] -d offline_packages
```

### 8.2 CUDA/GPU 支持

错误: CUDA not available

```
# 设置: CPU 模式 (默认)
# config/config.yaml 中 设置
yolo:
  device: "cpu" # 设置 "auto"
```

## 8.3 训练模型

错误: Can't load model from 'microsoft/layoutlmv3-base'

```
# 错误: 训练模型失败
# scripts/train_layoutlm_simple.py
model_name = "offline_models/layoutlmv3-base"
```

## 8.4 内存溢出

错误: Out of memory

```
# 错误: 内存溢出
# scripts/train_layoutlm_simple.py
per_device_train_batch_size=1 # 2 → 1 解决
```

## 8.5 EasyOCR 模型训练

错误: Model file not found

```
# 错误: EasyOCR 模型文件未找到
ls ~/.EasyOCR/model/

# 复制模型文件
cp -r offline_models/easyocr/* ~/.EasyOCR/model/
```

# 9. 项目结构

```
doc-classifier/
├── offline_packages/      # 离线 Python 包
├── offline_models/       # 离线模型
│   ├── layoutlmv3-base/
│   ├── easyocr/
│   └── yolov8n.pt
├── data/
│   ├── models/           # 模型
│   │   ├── yolo_document_layout/weights/best.pt
│   │   └── layoutlm_classifier/best/
│   ├── yolo_dataset/     # YOLO 数据集
│   └── sample/           # 样本
└── src/                  # 源代码
```

```
├── scripts/                # 脚本/脚本 脚本
├── api/                    # FastAPI 脚本
├── config/                 # 配置 脚本
├── run_api.py              # API 脚本 脚本
└── requirements.txt        # 依赖 脚本
```

## 10. 部署部署

### 部署部署 (部署部署)

- [ ] 部署部署 部署部署
- [ ] Python 部署部署 部署部署
- [ ] LayoutLMv3 部署部署
- [ ] YOLOv8n 部署部署
- [ ] EasyOCR 部署部署
- [ ] 部署部署

### 部署部署

- [ ] 部署部署
- [ ] 部署部署
- [ ] 部署部署 部署部署
- [ ] 部署部署 部署部署

### 部署部署 部署部署

- [ ] 部署部署 部署部署
- [ ] YOLO 部署部署 部署部署
- [ ] YOLO 部署部署
- [ ] YOLO 部署部署 部署部署
- [ ] LayoutLM 部署部署
- [ ] LayoutLM 部署部署 部署部署
- [ ] API 部署部署 部署部署